

UNIVERSITAS PERTAMINA

Fakultas Sains dan Komputer — Ilmu Komputer

TUGAS KELOMPOK (PROYEK AKHIR)

Mata Kuliah Deep Learning

Membangun Sistem NLP untuk Bahasa Indonesia atau Bahasa Daerah *"Dari Data hingga Demo"*

Bobot: 40% Nilai Akhir | Kelompok: 4–5 Mahasiswa

Pengantar dan Tujuan

Tugas kelompok ini adalah komponen dengan bobot terbesar (40%). Tujuannya adalah memberikan pengalaman membangun sistem NLP secara bertahap: dari data, *baseline* klasik, model *neural*, hingga *fine-tuning* model *pre-trained* — lalu mendemonstrasikan dan mempresentasikannya.

Alur Kerja

Pilih Task → Kumpulkan Data → Baseline (TF-IDF) → Fine-tune IndoBERT → Evaluasi & Error Analysis → Demo → Presentasi + Ringkasan

Bonus Bahasa Daerah

KETENTUAN BONUS (+10 poin dari nilai proyek)

Kelompok yang menggunakan bahasa daerah sebagai bahasa target mendapat bonus +10 poin. Kabar baiknya: kini tersedia dataset siap pakai untuk 10 bahasa daerah melalui NusaX, sehingga kelompok TIDAK perlu mengumpulkan data dari nol.

Bahasa daerah yang didukung NusaX: Aceh, Bali, Banjar, Bugis, Madura, Minang, Jawa, Ngaju, Sunda, Batak Toba.

Mengapa menarik: hampir tidak ada benchmark untuk bahasa-bahasa ini, sehingga hasil kelompok berpotensi menjadi kontribusi nyata.

Aturan Penggunaan AI dalam Tugas

AI generatif (ChatGPT, Claude, Gemini, GitHub Copilot, dan sejenisnya) adalah bagian dari realita kerja NLP modern. Tugas ini TIDAK melarang penggunaan AI, tetapi mengaturnya agar pembelajaran tetap terjadi dan integritas akademik terjaga. Prinsip dasarnya: AI boleh menjadi asisten, bukan pengganti pemahaman Anda.

Yang DIPERBOLEHKAN

Kategori	Contoh penggunaan yang diizinkan
Bantuan koding	Debugging error, menjelaskan pesan error, melengkapi boilerplate (loading data, plotting), refactor kode yang sudah Anda tulis
Pemahaman konsep	Bertanya penjelasan konsep (apa itu attention, cara kerja BERT), meminta analogi, klarifikasi materi kuliah
Perbaikan tulisan	Memperbaiki tata bahasa, merapikan kalimat, menerjemahkan istilah pada ringkasan dan slide
Eksplorasi ide	<i>Brainstorming</i> pendekatan, mencari kandidat dataset, membandingkan arsitektur secara konseptual
Pencarian referensi	Menemukan paper terkait (wajib diverifikasi keberadaannya — jangan percaya sitasi mentah dari AI)

Yang TIDAK DIPERBOLEHKAN

Kategori	Contoh yang dilarang
Menyalin mentah	Menyalin seluruh kode pipeline/model dari AI tanpa memahami dan tanpa memodifikasinya
Hasil fiktif	Menggunakan angka hasil eksperimen, tabel, atau grafik yang dibuat (di- <i>generate</i>) AI tanpa benar-benar menjalankan eksperimen
Analisis palsu	Meminta AI menulis <i>error analysis</i> atau kesimpulan tanpa Anda benar-benar menganalisis hasil model sendiri
Sitasi halusinasi	Mencantumkan referensi/paper yang disarankan AI tanpa memverifikasi bahwa paper tersebut benar-benar ada
Mengaku tanpa AI	Menyatakan tidak memakai AI padahal memakai (pelanggaran transparansi)

Kewajiban Transparansi: Lampiran Penggunaan AI

Setiap kelompok WAJIB menyertakan satu halaman "Lampiran Penggunaan AI" di akhir ringkasan, yang menjelaskan secara jujur bagaimana AI digunakan. Kejujuran di sini tidak mengurangi nilai — justru ketidakjujuran yang berisiko sanksi.

Format Lampiran Penggunaan AI (contoh)

- Tool yang digunakan: ChatGPT (GPT-4), GitHub Copilot
- Untuk apa: debugging dataloader PyTorch, menjelaskan konsep attention, merapikan tata bahasa ringkasan
- Untuk apa TIDAK digunakan: seluruh eksperimen dijalankan sendiri, error analysis ditulis sendiri berdasarkan output model
- Contoh prompt penting (opsional): "Jelaskan mengapa gradient saya NaN saat training LSTM"

Verifikasi Pemahaman

Saat presentasi, dosen akan mengajukan pertanyaan teknis kepada anggota secara acak. Setiap anggota harus mampu menjelaskan kode, keputusan desain, dan hasil — termasuk bagian yang dibantu AI. Ketidakmampuan menjelaskan pekerjaan sendiri akan menurunkan nilai secara signifikan, terlepas dari kualitas hasil akhir.

Jika Anda tidak bisa menjelaskan suatu baris kode atau angka hasil kepada dosen, jangan masukkan ke dalam tugas Anda.

Pilihan Task & Dataset Tervalidasi

Setiap kelompok memilih SATU task. Seluruh dataset di bawah telah diverifikasi tersedia dan dapat diakses publik (mayoritas melalui Hugging Face dengan `datasets.load_dataset`). Untuk opsi bonus bahasa daerah, gunakan NusaX yang sudah berisi 10 bahasa daerah siap pakai.

TASK A

Analisis Sentimen Teks Indonesia

Klasifikasi sentimen (positif / negatif / netral) pada komentar dan ulasan berbahasa Indonesia.

Aspek	Detail / Link
Dataset utama	indonlp/indonlu — subset SmSA (3 kelas, ribuan ulasan, lisensi MIT)
Dataset alternatif	SEACrowd/smsa (versi SmSA via SEACrowd)
Dataset BONUS daerah	indonlp/NusaX-senti — sentimen 10 bahasa daerah, CC-BY-SA 4.0
Metrik	Accuracy, F1-macro, F1-weighted

TASK B

Deteksi Hoaks / Berita Palsu

Klasifikasi teks berita atau klaim sebagai HOAX vs NON-HOAX (atau fakta vs hoaks).

Aspek	Detail / Link
Dataset utama	nlp-brin-id/fakenews-mafindo — data turnbackhoax.id / Mafindo 2018–2023
Dataset alternatif	Rifky/indonesian-hoax-news (siap <code>load_dataset</code>)
Dataset tambahan	GitHub: rifkybujana/FND — 3 sumber digabung (~2.220 berita)
Catatan	<i>Dataset "Politifact-ID" pada versi lama TIDAK valid untuk Bahasa Indonesia — gunakan dataset di atas.</i>
Metrik	Accuracy, F1, perhatikan class imbalance (gunakan F1-macro)

TASK C

Named Entity Recognition (NER)

Mengenali entitas (orang, lokasi, organisasi, dll.) dalam teks Indonesia.

Aspek	Detail / Link
-------	---------------

Dataset utama	grit-id/id_nergrit_corpus — NERGrit, 18 jenis entitas, format IOB
Subset sederhana	indonlp/indonlu — subset NERGrit/NERP (3–5 entitas)
Dataset alternatif	SEACrowd/nergrit (via SEACrowd)
Metrik	Entity-level F1 (gunakan library seqeval)

TASK D**Question Answering Bahasa Indonesia**

Extractive QA: menemukan span jawaban dari sebuah konteks teks Indonesia.

Aspek	Detail / Link
Dataset utama	khalidalt/tydiqa-goldp — pilih split bahasa Indonesia (id)
Dataset alternatif	SEACrowd/tydiqa_id (split Indonesia khusus)
Model awal	cahya/bert-base-indonesian-tydiqa (referensi baseline)
Metrik	Exact Match (EM) dan F1 span-level

TASK E**Text Summarization Bahasa Indonesia**

Meringkas artikel berita Indonesia (extractive atau abstractive).

Aspek	Detail / Link
Dataset utama	SEACrowd/indosum — IndoSum, berita + ringkasan manual
Dataset alternatif	csebuetnlp/xlsum — pilih config 'indonesian'
Model awal	csebuetnlp/mT5_multilingual_XLSum (referensi)
Metrik	ROUGE-1, ROUGE-2, ROUGE-L

Untuk Opsi Bahasa Daerah (Bonus) — Lintas Task

Dataset	Detail / Link
NusaX-senti	indonlp/NusaX-senti — sentimen 10 bahasa daerah (untuk Task A)
NusaX-MT	indonlp/NusaX-MT — paralel terjemahan 10 bahasa daerah
Model multibahasa	xlm-roberta-base atau bert-base-multilingual-cased untuk fine-tuning bahasa daerah

Model Pre-trained yang Direkomendasikan

Untuk tahap fine-tuning, gunakan salah satu model berikut. Semua tersedia di Hugging Face dan dapat dimuat dengan AutoModel.

Model	Keterangan / Link
IndoBERT (utama)	indobenchmark/indobert-base-p1 — DIREKOMENDASIKAN untuk Bahasa Indonesia
IndoBERT (IndoLEM)	indolem/indobert-base-uncased — alternatif
XLM-RoBERTa	FacebookAI/xlm-roberta-base — multilingual, baik untuk bahasa daerah
mBERT	google-bert/bert-base-multilingual-cased — baseline multilingual
mT5 (untuk summarization)	google/mt5-small — untuk Task E abstractive

Deliverables

Berikut yang WAJIB dikumpulkan — tidak lebih:

Deliverable	Format	Keterangan
1. Notebook	1 file .ipynb	Berisi seluruh pipeline: data → baseline → fine-tuning → evaluasi. Sudah dijalankan (output terlihat), diberi komentar
2. Slide Presentasi	PDF / PPTX (10–12 slide)	Menggantikan laporan ilmiah penuh. Lihat struktur di bawah
3. Ringkasan	2 halaman (PDF)	Ringkasan tertulis singkat + Lampiran Penggunaan AI
4. Demo	Link Hugging Face Spaces / Colab	Demo sederhana yang bisa menerima input dan menampilkan prediksi

Struktur Slide Presentasi (10–12 slide)

Slide	Isi
1	Judul, anggota kelompok, task & bahasa yang dipilih
2	Masalah & motivasi (mengapa task ini penting)
3	Dataset: sumber, jumlah sampel, distribusi kelas
4	Preprocessing singkat & baseline (TF-IDF + classifier)
5–6	Fine-tuning model: model yang dipakai, setup, hasil
7	Tabel perbandingan: baseline vs fine-tuned
8	Error analysis: 5–8 contoh menarik + insight
9	Demo (screenshot atau live)
10	Kesimpulan & keterbatasan
11	Lampiran Penggunaan AI

Struktur Ringkasan (2 Halaman)

- Halaman 1: Masalah, dataset (dengan link), metode (baseline + fine-tuning), dan tabel hasil utama
- Halaman 2: Error analysis singkat (5–8 contoh), keterbatasan, kesimpulan, dan Lampiran Penggunaan AI

Timeline & Penilaian

Timeline (Pekan 12 → UAS)

Pekan	Aktivitas
Pekan 12	Pembentukan kelompok + pemilihan task & dataset. Kumpulkan proposal singkat (1 halaman)
Pekan 13	Kerja mandiri: data + baseline TF-IDF berjalan
Pekan 14	CHECKPOINT progress (15 menit/kelompok): tunjukkan baseline + progress fine-tuning
Pekan 15	Finalisasi fine-tuning + demo + siapkan slide. Dry run opsional
UAS	Presentasi final (12 menit + 8 menit tanya jawab) + kumpulkan semua deliverable

Proposal Singkat (1 Halaman) — Pekan 12

- Task & bahasa yang dipilih, serta dataset (sertakan link)
- Masalah yang diselesaikan dan mengapa relevan
- Rencana model: baseline + model pre-trained yang akan di-fine-tune
- Pembagian tugas antar anggota

Format Presentasi (15 + 10 Menit)

Alokasi Waktu	Konten
2 menit	Motivasi dan masalah — langsung ke masalah nyata, bukan teori
3 menit	Dataset dan tantangan data
5 menit	Arsitektur dan eksperimen — fokus pada yang paling menarik
3 menit	Demo live sistem
2 menit	Error analysis dan kesimpulan
10 menit	Tanya jawab — dosen bertanya ke anggota secara acak

Catatan Penting Presentasi

Setiap anggota kelompok WAJIB berbicara minimal satu bagian. Selama sesi tanya jawab, dosen dapat mengarahkan pertanyaan kepada anggota mana pun — bukan hanya ketua kelompok. Kemampuan menjawab pertanyaan teknis secara individual adalah bagian dari penilaian.

Rubrik Penilaian

Komponen	Bobot	Kriteria
Dataset & Baseline	15%	Data dimuat dengan benar, statistik jelas, baseline TF-IDF berjalan dan dilaporkan
Fine-tuning & Hasil	30%	Model pre-trained di-fine-tune dengan benar, perbandingan dengan baseline, justifikasi keputusan
Error Analysis	20%	5–8 contoh error dianalisis, insight bermakna, diskusi keterbatasan
Demo	10%	Demo berjalan dan dapat menerima input pengguna
Slide & Ringkasan	10%	Slide jelas, ringkasan padat, Lampiran AI terisi jujur
Presentasi	15%	Semua anggota berkontribusi & mampu menjawab pertanyaan teknis
BONUS Bahasa Daerah	+10	Menggunakan NusaX / data bahasa daerah + analisis tantangan linguistik

Catatan tentang Error Analysis (20%)

Meski deliverables dikurangi, error analysis tetap berbobot besar. Yang dinilai bukan hanya "berapa akurasi model", tetapi "mengapa model salah di kasus tertentu, dan apa yang bisa diperbaiki". Inilah inti dari kemampuan analitis seorang praktisi NLP.

Pesan Penutup untuk Mahasiswa

Yang membedakan tugas ini dari tugas biasa adalah kemungkinan bahwa pekerjaan Anda benar-benar bermakna di luar kelas. Untuk bahasa daerah tertentu, dataset yang Anda kumpulkan dan benchmark yang Anda buat bisa menjadi satu-satunya sumber daya NLP yang tersedia untuk bahasa tersebut — setidaknya untuk beberapa waktu ke depan. Ini bukan ketertinggalan — ini adalah keunggulan komparatif. Di saat peneliti dari negara lain harus bersaing di bidang yang sudah sangat ramai (NLP Bahasa Inggris, Mandarin, Arab), Anda memiliki akses ke 700+ bahasa yang hampir tidak tersentuh oleh teknologi NLP modern.

Selamat bereksplorasi.

Kelanjutan: *Summer Project*

Perkuliah ini bukan akhir dari proyek Anda. Bagi kelompok yang merasa proyeknya menarik dan ingin membawanya lebih jauh, proyek ini dirancang agar dapat berkembang menjadi penelitian yang lebih serius melalui *summer project* setelah semester berakhir.

Yang dibutuhkan untuk melanjutkan bukanlah hasil yang sempurna di kelas, melainkan rasa ingin tahu dan kemauan untuk menggali lebih dalam.

Mengapa Proyek Ini Layak Dilanjutkan

Proyek yang dikerjakan dalam mata kuliah ini menyentuh masalah-masalah NLP yang masih terbuka, terutama untuk konteks Indonesia. Kelompok yang mengerjakan bahasa daerah memiliki posisi yang sangat istimewa — karena hampir tidak ada *benchmark* yang tersedia, pekerjaan Anda berpotensi menjadi kontribusi nyata yang dapat dipublikasikan dan digunakan oleh peneliti lain di seluruh dunia.

Jalur Pengembangan yang Mungkin

Jalur	Penjelasan
Publikasi ilmiah	Proyek kelas yang baik dapat diperdalam menjadi paper untuk disubmit ke konferensi atau workshop NLP — misalnya workshop khusus bahasa <i>low-resource</i> atau <i>venue</i> NLP regional Asia Tenggara
Rilis dataset publik	Jika kelompok mengumpulkan atau menganotasi data baru (terutama bahasa daerah), dataset tersebut dapat dirilis di Hugging Face sebagai sumber daya publik dan menjadi rujukan bagi peneliti lain
Fondasi tugas akhir	Proyek dapat menjadi dasar untuk topik skripsi atau tugas akhir, dengan ruang lingkup yang diperluas dan metodologi yang diperdalam
Bimbingan lanjutan	Mahasiswa yang berminat dapat memperoleh bimbingan lanjutan dari dosen selama periode <i>summer</i> untuk mengarahkan penelitian

Cara Mendaftar

Kelompok atau individu yang tertarik melanjutkan proyeknya sebagai *summer project* dipersilakan menyampaikannya kepada dosen menjelang akhir semester. Diskusi awal akan mencakup ruang lingkup yang ingin dicapai, target keluaran (paper, dataset, atau prototipe), serta bentuk dan jadwal bimbingan selama periode *summer*.

Catatan

Keikutsertaan dalam *summer project* bersifat sukarela dan tidak memengaruhi nilai mata kuliah ini. Ini adalah kesempatan tambahan bagi mahasiswa yang ingin merasakan pengalaman penelitian NLP yang sesungguhnya — dari sebuah ide di kelas hingga menjadi kontribusi yang nyata — atau ingin melanjutkan penelitian ini menjadi tugas akhir.